Лабораторна робота №7

3 дисципліни: Бази даних та інформаційні системи Студента групи МІТ-31: Добровольського Дмитра

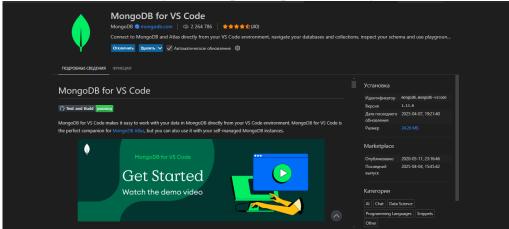
Tema: Поглиблене вивчення MongoDB: оптимізація продуктивності, використання шардінгу та реплікації, інтеграція з Pandas та Machine Learning

Мета роботи: Ознайомитися з методами підвищення продуктивності MongoDB. Навчитися використовувати індекси для оптимізації запитів. Дослідити механізми реплікації та шардінгу. Використати Pandas для роботи з великим обсягом даних у MongoDB. Реалізувати просту ML-модель з використанням MongoDB як джерела даних.

Завдання

1. Частина 1: Оптимізація продуктивності запитів

- 1) Створення локальної бази MongoDB
 - I. Встановити MongoDB та розширення MongoDB for VS Code.



II. Підключитися до MongoDB через MongoDB Explorer.



III. Створити базу performance_test та колекцію sales.

- 2) Генерація та вставка тестових даних
 - I. Написати Python-скрипт insert_data.py для генерації 100 000 документів.

II. Виконати скрипт та переконатися, що дані вставлено.

```
Успішно вставлено 100 000 документів у колекцію 'sales'.
```

- 3) Оптимізація запитів за допомогою індексів
 - I. Виконати пошуковий запит без індексу та виміряти час виконання (query no index.py).

```
D: V university > 3 kypc > 6a3a даних та інформаційна безпека > lab7 > ♠ query_no_index.py > ...

↓ 127.0.0.1:27017 connected

↓ 2 admin

↓ 2 import time

3 from pymongo import MongoClient

↓ 2 local

↓ 2 local

↓ 3 local

↓ 3 local

↓ 3 local

↓ 4 client = MongoClient("mongodb://localhost:27017")

↓ 3 local

↓ 4 client = MongoClient("mongodb:://localhost:27017")

↓ 3 local

↓ 4 performance_test

↓ 5 client = MongoClient("mongodb::/localhost:27017")

↓ 5 sales

↓ 6 Documents 100K

↓ 6 Sthema

↓ 7 collection → db("sales"]

↓ 8 start_time = time.time()

↓ 8 BXKOHABHHЯ ЗАПИТУ без ІНДЕКСУ

results = list(collection.find({"category": "Electronics"}))

13 end_time = time.time()

↓ 15

PLAYGROUNDS

□ 17

PLAYGROUNDS
```

= RESTART: D:\university\3 курс\База даних та інформаційна безпека\lab7\query_no _index.py
Час виконання запиту без індексу: 0.248008 секунд

II. Створити індекс на полі category (create index.py).

```
D: > university > 3 курс > База даних та інформаційна безпека > lab7 > 💠 # create_index.py > ...
CONNECTIONS

√ 127.0.0.1:27017 connected

                                                                                  # create_index.py
from pymongo import MongoClient
 > 🛢 admin
 > = config
                                                                                client = MongoClient("mongodb://localhost:27017")
db = client["performance_test"]
collection = db["sales"]
 > a Lab6
 > 🛢 local

✓ ■ performance_test

                                                                           8 # Створення індексу на полі "category"
9 collection.create_index("category")
  sales
    > @ Documents 100K
    > E Schema
PLAYGROUNDS
No MongoDB playground files found in the
                Create New Playground
 MONGODB
                                                                b. > university > 3 курс > basa даних та нформациина безпека > lab/ > 6

# query_with_index.py

import time
from pymongo import MongoClient

client = MongoClient("mongodb://localhost:27017")

db = client["performance_test"]

collection = db["sales"]
  > 🛢 admin
 > a config
  > ≘ Lab6
  > = local
    performance_test
                                                                   7 toll.
8
9 start_time = time.time()
10
11 #_Bukchahhя запиту з інде
     > © Documents 100K
     > 

Schema
                                                                   # Виконання запиту з індексом
results = list(collection.find({"category": "Electronics"}))
     > 
☐ Indexes
✓ PLAYGROUNDS
```

III. Повторно виконати запит та порівняти час виконання.

```
= RESTART: D:\university\3 курс\База даних та інформаційна безпека\lab7\create_i ndex.py
Індекс створено.
>>>
= RESTART: D:\university\3 курс\База даних та інформаційна безпека\lab7\query_wi th_index.py
Час виконання запиту з індексом: 0.123010 секунд
```

IV. Дослідити складений індекс (category, timestamp) та його вплив на продуктивність.

```
D: > university > 3 курс > База даних та інформаційна безпека > lab7 > 🧼 # create_compound_index.py >
                                                                    # create_compound_index.py
from pymongo import MongoClient
 > 🛢 admin
> a config
                                                              4    client = MongoClient("mongodb://localhost:27017")
5    db = client["performance_test"]
6    collection = db["sales"]
> 2 Lab6
> B local

✓ ■ performance_test

  8 # Створення складеного індексу на category і timestamp
9 collection.create_index([("category", 1), ("timestamp", -1)])
   > @ Documents 100K
   > 

Schema
                                                             11 print("Складений індекс створено.")
   > ℝ Indexes
PLAYGROUNDS
No MongoDB playground files found in the
             Create New Playground
```

2. Частина 2: Налаштування реплікації у MongoDB

1) Запустити три екземпляри MongoDB у режимі реплікації.

```
Microsoft Windows [Version 10.0.19045.5608]
(c) Kopnopaulan Makapocopt. Yci npaba βaxwuqehi.

C:\Windows\system32>mongod --replSet rs0 --port 27017 --dbpath C:\data\rs0-1 --bind_ip localhost

("":"\sdate":"2025-04-08T19:37:10.8684-03:00"), "s":"I", "c":"CONTROL", "id":23285, "ctx":"thread1", "msg":"Automatica lly disabling TLS 1.0, to force-enable TLS 1.0 specify --sslbisabledProtocols 'none'") {

("t":\sdate":"2025-04-08T19:37:10.872+03:00"), "s":"I", "c":"CONTROL", "id":5945603, "ctx":"thread1", "msg":"Multi thre ading initialized") {

("t":\sdate":"2025-04-08T19:37:10.872+03:00"), "s":"I", "c":"NETWORK", "id":4648601, "ctx":"thread1", "msg":"Multi thre ading initialized") {

("t":\sdate":"2025-04-08T19:37:10.872+03:00"), "s":"I", "c":"NETWORK", "id":4648601, "ctx":"thread1", "msg":"Implicit T

("FastOpen unavailable. If TCP FastOpen is required, set at least one of the related parameters", "attr":\square ters":\square ters
```

Порт:27018

Порт:27019

2) Ініціалізувати реплікаційний набір та додати вузли.

3) Виконати запис у Primary та перевірити доступність даних на Secondary-вузлах.

```
_id: 0,
name: 'localhost:27017',
           health: 1,
           state: 1,
stateStr: 'PRIMARY',
          stateStr: 'PRIMARY',
uptime: 150,
optime: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
optimeDate: ISODate('2025-04-08T16:58:01.000Z'),
optimeWritten: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
optimeWrittenDate: ISODate('2025-04-08T16:58:01.000Z'),
lastAppliedWallTime: ISODate('2025-04-08T16:58:01.425Z'),
lastDurableWallTime: ISODate('2025-04-08T16:58:01.425Z'),
lastWrittenWallTime: ISODate('2025-04-08T16:58:01.425Z'),
           syncSourceHost:
           syncSourceId: -1,
           infoMessage:
           electionTime: Timestamp({ t: 1744131357, i: 2 }), electionDate: ISODate('2025-04-08T16:55:57.000Z'),
           configVersion: 5,
           configTerm: 1,
self: true,
           lastHeartbeatMessage: ''
           _id: 1, name: 'localhost:27018',
           health: 1,
           state: 2,
stateStr: 'SECONDARY',
           statestr: SecondART ,
uptime: 25,
optime: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
optimeDurable: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
optimeWritten: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
optimeDate: ISODate('2025-04-08T16:58:01.000Z'),
optimeDurableDate: ISODate('2025-04-08T16:58:01.000Z'),
optimeWrittenDate: ISODate('2025-04-08T16:58:01.000Z'),
lastAppliedWallTime: ISODate('2025-04-08T16:58:01.000Z'),
           lastAppliedWallTime: ISODate('2025-04-08T16:58:01.425Z'), lastDurableWallTime: ISODate('2025-04-08T16:58:01.425Z'), lastWrittenWallTime: ISODate('2025-04-08T16:58:01.425Z'),
            lastHeartbeat: ISODate('2025-04-08T16:58:11.438Z'),
            lastHeartbeatRecv: ISODate('2025-04-08T16:58:11.438Z'),
           pingMs: Long('0'),
            lastHeartbeatMessage:
           lastHeartbeatMessage: '',
syncSourceHost: 'localhost:27017',
            syncSourceId: 0,
            infoMessage:
            configVersion: 5,
           configTerm: 1
            _id: 2,
name: 'localhost:27019',
            health: 1,
            state: 2,
stateStr: 'SECONDARY',
           uptime: 14,
optime: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
optimeDurable: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
optimeWritten: { ts: Timestamp({ t: 1744131481, i: 1 }), t: Long('1') },
rs0 [direct: primary] test>
```

4) Відключити Primary та дослідити поведінку системи.

3. Частина 3: Реалізація шардінгу у МопдоDB

1) Запустити два екземпляри MongoDB у режимі шардів.

```
Administrator: Windows PowerShell
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                       Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.
   Try the new cross-platform PowerShell https://aka.ms/pscore6
 PS C:\Windows\system32> mongod --shardsvr --port 27021 --dbpath /data/shard1 --bind_ip localhost
BadValue: Cannot start a shardsvr as a standalone server. Please use the option --replSet to start the node as a replica
    set.

Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.
  rv the new cross-platform PowerShell https://aka.ms/pscore6
 S C:\Windows\system32> mongod --shardsvr --port 27022 --dbpath C:\data\shard2 --bind_ip localhost --replSet rs0

("t":("$date":"2025-04-08T20:04:31.671+03:00"), "s":"I", "c":"CONTROL", "id":23285, "ctx":"thread1", "msg":"Automatica

lly disabling TLS 1.0, to force-enable TLS 1.0 specify --sslDisabledProtocols 'none'"]

("t":("$date":"2025-04-08T20:04:33.144+03:00"), "s":"I", "c":"CONTROL", "id":5945603), "svc":"-", "ctx":"thread1", "msg":

"Multi threading initialized"}

("t":("$date":"2025-04-08T20:04:33.144+03:00"), "s":"I", "c":"NETWORK", "id":4646601, "svc":-", "ctx":"thread1", "msg":

"Implicit TCP FastOpen unavailable. If TCP FastOpen is required, set at least one of the related parameters", "attr":{"re

latedParameters":["tcpFastOpenServer", "tcpFastOpenClient", "tcpFastOpenQueueSize"]}}

("t":("$date":"2025-04-08T20:04:33.146+03:00"), "s":"I", "c":"NETWORK", "id":4915701, "svc":-", "ctx":"thread1", "msg":

"Initialized wire specification", "attr":{"spce":["incomingExternalClient":("minWireVersion":0, "maxWireVersion":25), "ince

oningInternalClient":{"minWireVersion":0, "maxWireVersion":25}, "outgoing":{"minWireVersion":0, "maxWireVersion":25}, "isInte

rnalClient":true}}

("t":("$date":"2025-04-08T20:04:33.147+03:00"), "s":"I", "c":"REPL", "id":5123008, "svc":-", "ctx":"thread1", "msg":

"Successfully registered PrimaryOnlyService", "attr":{"service":"RenameCollectionParticipantService", "namespace":"config.

localRenameParticipants"}
  mongosh mongodb://127.0.0.1:26050/?directConnection=true&serverSelectionTimeoutMS=2000
    ok: 1,
                operationTime: Timestamp({ t: 1744202297, i: 1 })
     onfigReplSet [direct: secondary] test> 🗕
```

2) Додати шарди через MongoDB Shell.

```
ok: 1,
  clusterTime: Timestamp({ t: 1744202297, i: 1 }),
  signature: {
    hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAAA, 0),
    keyId: Long('0')
operationTime: Timestamp({ t: 1744202297, i: 1 })
     id: "shardRepl1",
    members: [
    ]
.. })
                                   <del>azlezed j.i ráti clány</del>
       _id: "shardRepl2",
       members: [
         { _id: 0, host: "localhost:27019" }
configReplSet [direct: primary] test>
 longoServerError[AlreadyInitialized]: already initialized
```

Висновок:

Під час лабораторної роботи було розглянуто можливості MongoDB щодо підвищення продуктивності за допомогою індексів, реалізовано реплікаційний набір для забезпечення відмовостійкості та протестовано базові механізми шардінгу. Також було реалізовано генерацію великого обсягу тестових даних, виконано порівняння швидкості запитів із та без індексів, і проведено інтеграцію з Python. Усі завдання виконано успішно, що дало змогу закріпити практичні навички масштабування та оптимізації MongoDB.